翟开放

15529607820 · zkfopen@foxmail.com · 1995 年生 · 北京

职业概述

6 年以上后端、云原生与 AI Infra 研发经验。曾在百度从事 Kubernetes 私有化交付平台研发，现于智谱负责 MaaS 平台研发与模型部署，重点深入昇腾平台的推理性能优化。具备 PD 分离、长上下文与 KV Cache 验证经验，能够结合性能测试开展部署选型与容量规划。

技术能力

- **模型部署：**vLLM-Ascend、SGLang、MindIE；昇腾 910B/910C/950PR；W8A8 等量化模型部署、PD 分离、DP/TP/EP。
- **推理性能：**EvalScope perf、TTFT/TPOT、吞吐与容量分析；长上下文、前缀缓存、CPU KV 回载、UCM。
- **云原生与 MaaS：**Linux（Ubuntu、CentOS、麒麟）、Docker、Kubernetes、ARM64/AMD64、异构算力纳管、资源池与模型服务；Helm、Argo CD、CI/CD。
- **后端与自动化：**Go、client-go、Gin、Gorm、Python、Shell；权限与审计、REST API、MCP 服务。
- **可观测性与排障：**Prometheus、Grafana、Loki；模型服务、存储、网络、HCCL/RDMA 通信排障。

工作经历

智谱 | 大模型开发工程师

商业智能事业部 2025.05—至今

- **模型部署与交付：**负责 GLM、DeepSeek、Qwen 等模型的部署适配与方案选型，以昇腾 910B/910C/950PR 为主，面向中关村实验室、山东移动、中石化等客户完成模型部署上线、推理调优及服务故障排查。
- **MaaS 平台研发：**主导资源池、模型用量统计与算力监控等核心模块建设，完成 ARM64 适配及通算/智算双集群部署，打通模型实例下发链路；完成模型调用向 NewAPI 的迁移，保障迁移期间业务连续性。
- **推理性能工程：**建设 EvalScope perf 自动压测，开展长上下文、PD 拓扑与 KV Cache 方案对比，明确不同负载下的容量边界，输出部署选型、并发配置建议及标准化交付包。

百度 | 高级研发工程师

百度智能云事业群 2020.07—2025.05

- **云原生平台研发：**负责天牛 Kubernetes 集群生命周期与资源管理核心模块设计开发，建设权限校验、操作审计及多版本兼容能力，支撑 3000+ 集群累计托管与 1500+ 项目交付。
- **异构适配与制品交付：**完成 ARM64/AMD64、Ubuntu/麒麟环境适配，建设镜像及模型制品导入导出、差异资源交付与主辅包独立部署能力，支持异构环境下的私有化交付。
- **自动化与交付保障：**基于 Go、Kubernetes、Helm 建设巡检及集群预检查工具，完善代码评审、单元测试与自动化发布链路，将环境检查接入集群创建和扩容流程。

重点项目

中关村实验室 - 大模型 PD 分离部署与长上下文性能验证

项目技术负责人 2026.06—至今

面向昇腾 910C 长上下文推理场景，开展 GLM-5.2、GLM-5.3、DeepSeek-V4-Pro 模型部署工程化、PD 拓扑选型与缓存方案评估。

- **部署工程化：**在昇腾 910C 环境完成 GLM-5.2/5.3 量化模型的 PD 分离部署与 MaaS 上架，将 3P1D Docker 方案封装为 Helm Chart，通过 Argo CD 同步配置并验证扩缩容；完成 DeepSeek-V4-Pro 部署与问答验证。
- **拓扑选型：**基于 EvalScope perf 开展长上下文与多并发测试；在约 512K 输入、TTFT $<$ 30 秒及单路 Decode≥15 token/s 的目标下，对比验证 2P1D、1P1D 的并发承载能力，分别约为 16、8 并发，形成对应场景的拓扑与容量建议。
- **缓存方案评估：**对比 UCM 与合作方 KV Cache 优化版本：UCM 在 972.8K/8 并发下由全量失败变为 64/64 成功，但多数档位吞吐下降，判定收益有限；合作方版本在 786K/973K 下 TTFT 最大 223.07→23.48 秒、整体吞吐最大 12,601→60,941 tok/s，据此给出方案适用范围。
- **排障与达标验证：**定位 Proxy 启动与请求分发异常，修复后由 1P1D 调整为 3P1D；GLM-5.3 在 1024K/4 并发/90% 前缀下 TTFT 13.72 秒、TPOT 49.06ms，满足 $\leq$ 40s/$\leq$ 50ms 目标。

山东移动 - 国产化 MaaS 与模型部署优化

项目技术负责人 2025.06—至今

建设 ARM64 与昇腾环境下的私有化 MaaS 平台，支撑百卡级算力集群的统一管理与模型服务部署，推进 GLM-5.3-Flash 部署适配与性能验证。

- **国产化 MaaS 建设：**完成 MaaS API、Infra 及配套组件的 ARM64 适配，建设通算、智算双 Kubernetes 集群并打通模型实例下发与调用链路；为 GLM、DeepSeek、Qwen 等 13 个去重模型制定部署方案并指导现场实施，将 TTS、ASR 服务封装为 Helm Chart 纳管至 MaaS。
- **Flash 部署与压测：**基于 vLLM-Ascend 制定 GLM-5.3-Flash-W8A8 的 910C 单机 TP16、910B 单机 TP8 及双机 1P1D 部署方案（P 节点：DP1/TP1/PCP8；D 节点：DP4/TP2/PCP1），实现部署脚本化与 EvalScope perf 自动压测，完成不同硬件与拓扑的性能对比。
- **KV Cache 验证：**在 910B、16K 前缀受控测试中，验证 CPU KV Offloading 使 TTFT 从 4.14 秒降至 0.822 秒；在 910B 双机、512K 共享前缀输入、8 并发下，测得单路 Decode 超过 10 token/s。

中石化 - 人工智能中台 MaaS 与模型服务

项目技术负责人 2025.05—2026.04

面向大型能源央企建设私有化 MaaS 平台，统一管理千卡级异构算力与模型服务，支持模型推理、微调及 API 调用。

- **模型与算力交付：**累计交付 50+ 个去重模型，主导 GLM-4.7、DeepSeek-V3 部署与性能验证；将近 200 台裸金属服务器纳管至 Kubernetes，参与业务与昇腾算力集群拆分，制定节点下架、模型服务及对象存储迁移方案。
- **生产升级与保障：**负责 MaaS v2.0→v2.2 升级及定制代码、数据库、脚本迁移，通过演练、临时模型服务、网关切换与回滚准备保障升级，完成 5 个模型推理、2 个模型训练验证，验收无阻塞问题；定位 HCCL/RDMA 多机通信及 Kubernetes 故障，沉淀部署运维 SOP。

百度天牛私有化交付平台

核心模块负责人 2020.07—2025.05

面向私有化交付场景，长期负责集群管理、制品交付及自动化巡检模块的设计、研发与迭代。

模块一：Kubernetes 集群生命周期与异构平台建设

- 设计集群生命周期框架，覆盖创建、扩缩容等 11 项功能，支持 Kubernetes 1.20/1.24/1.28；完成 ARM64/AMD64、Ubuntu/CentOS/麒麟适配，支撑 60+ 多架构集群稳定运行，完善权限校验、审计与异常处理，平台交付时效提升 40%、故障率下降 65%。

模块二：大规模制品交付与存储优化

- 设计镜像架构识别与导出回退机制，重构镜像及模型文件加载逻辑，将 1TB 产品包导入由 2 小时缩短至 1 分钟，累计支撑 37,000+ 次导出；支持差异资源导出与主辅包独立部署，通过 CFS 存储与资源治理，将年度存储成本由约 40 万元降至约 1 万元。

模块三：自动化巡检与集群预检查

- 建设覆盖 300+ 业务场景的自动化巡检与 CLI 工具，将 15 项预检查接入集群创建、扩容流程，以 goroutine 并发执行；累计完成 10,000+ 次前置检查，集群启动成功率由 80% 提升至 98%，年均节省运维人力 150+ 人天。

荣誉认证

- 发明专利 2 项（2022 年），其中《资源信息处理方法、装置、电子设备以及存储介质》为第一作者。
- 获百度 ACG 体系交付服务奖（2023 Q2）、ACG 靠谱工程师（2021 Q4）及百度小赞奖。
- Kubernetes CKA 认证 | 2025.01

教育经历

西安电子科技大学	计算机科学与技术	硕士学位	2017.09—2020.06
河南工业大学	软件工程	学士学位	2013.09—2017.06